Challenge 1

Nicola Pinat [SM3201546]

1 Introduzione

Il dataset utilizzato contiene informazioni di banconote, in particolare di contraffatte e autentiche. E' stata usata una telecamera industriale per digitalizzare le banconote, la stessa usata per il "print inspection". Ci viene detto che le immagini hanno 400 x 400 pixel e ci sono imprecisioni nell'immagine date dalle lenti e dalla distanza. E' stato usato "Wavelet transform tool" per l'estrazione delle features dalle immagini.

Il dataset è multivariato e il trasformatore ci ha dato queste features

- Varianza
- Asimmetria
- Curtosi
- Entropia
- Classe

Tutte le variabili sono continue apparte l'ultima, classe infatti è categorica: 0,1

2 Obiettivi e metodi

Il nostro è un problema di classificazione binaria, dividiamo il lavoro in 3 parti: caricamento dei dati e preprocessing, unsupervised learning (PCA, k-means, T-SNE, DBSCAN) e costruzione di modelli di supervised learning (logistic regression, Naive-Bayes, KNN, decision trees)

3 Preprocessing

Nonostante la fonte dei dati ci dice che non sono presenti valori mancanti, eseguiamo una visualizzazione preliminare confermando ciò. Inoltre plottiamo qualche grafico per visualizzare la distribuzione dei dati, divisi per classe per essere precisi

Notiamo chiaramente una asimmetria nei dati in kurtosis e entropy. Le variabili sono oltretutto in scale diverse. Standardizziamo le variabili ai fini di una corretta esecuzione degli algoritmi usando *StandardScaler*. Inoltre si è deciso di mescolare casualmente i dati in quanto essendo divisi per classe per poter effettuare campionamenti in seguito.

Il dataset è stato diviso in training e test nel rapporto 30/70.

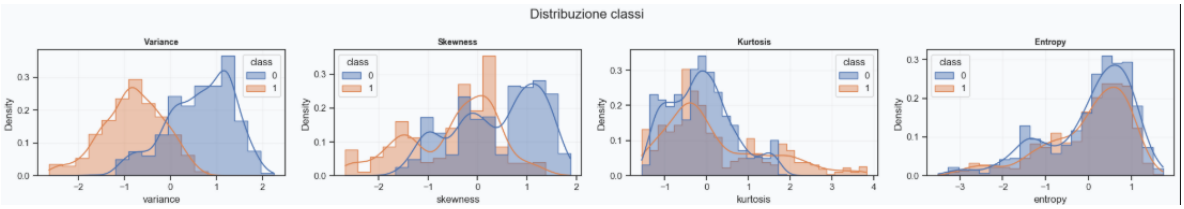

Figure 1: Distribuzione delle variabili

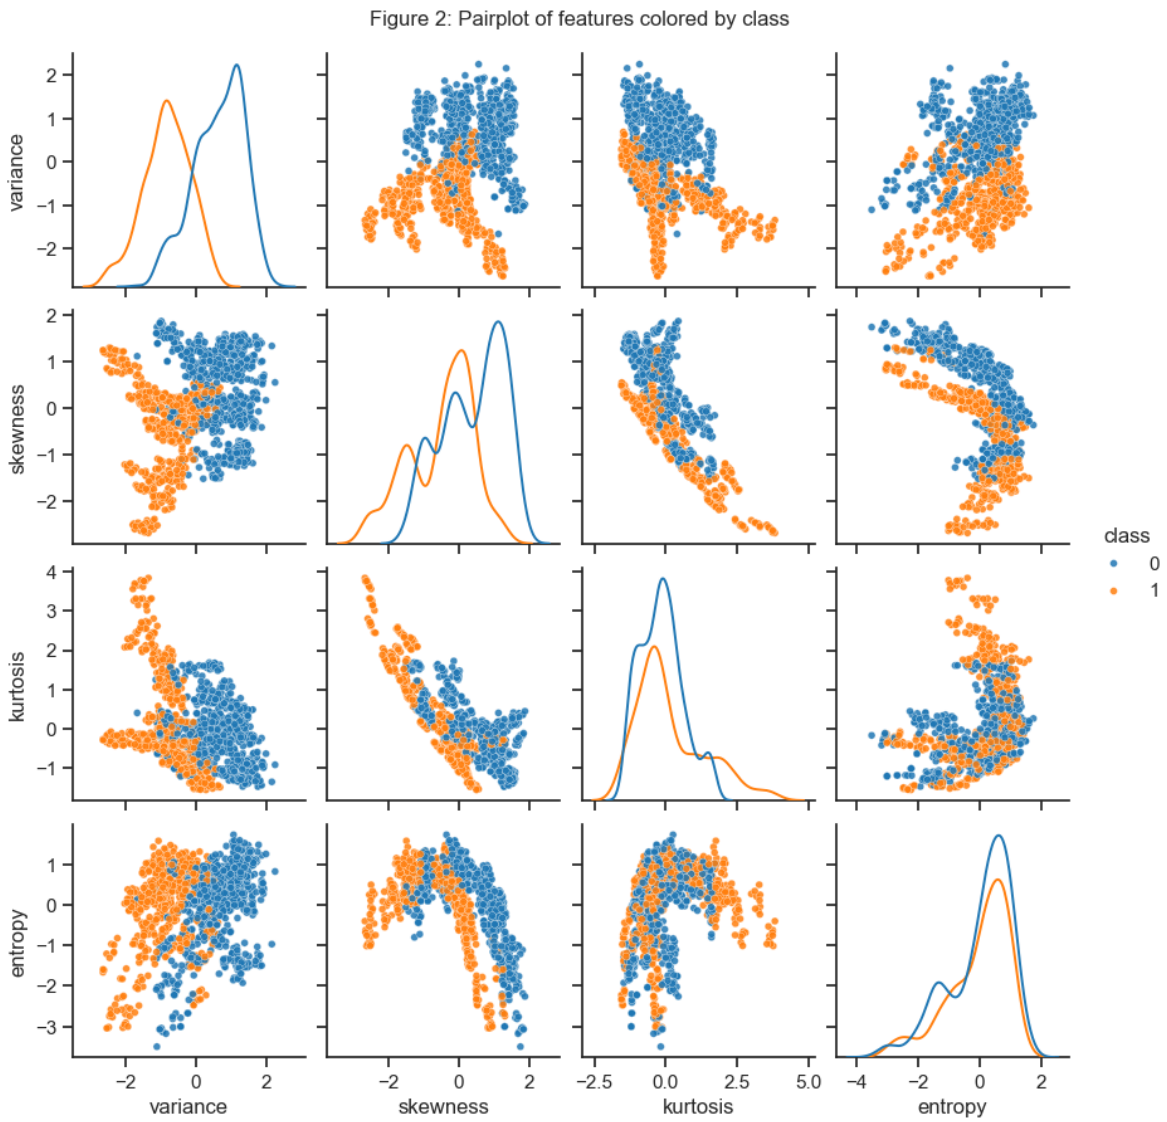

Figure 2: Pairplot delle classi

4 Unsupervised learning

Si è deciso di indagare il dataset con l'unsupervised learning. Vengono usati PCA, K-means e DBSCAN come algoritmi per il dataset, con PCA andiamo a ridurre la dimensionalità del dataset, con K-means e DBSCAN verifichiamo se è possibile separare linearmente le classi dopo l'applicazione di PCA.

Risultati dell'analisi di seguito

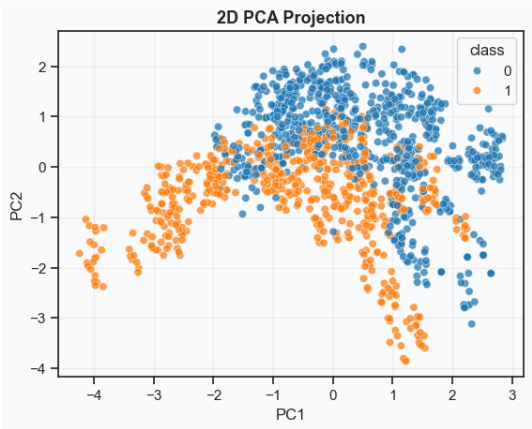

Figure 3: 2D PCA

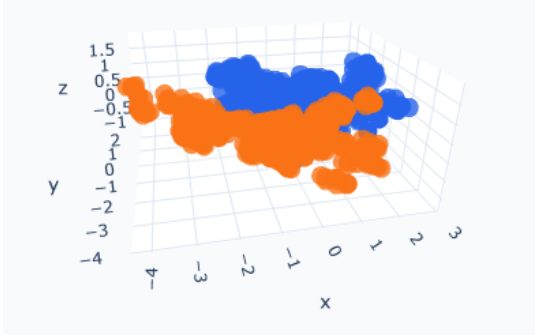

Figure 4: 3D PCA

Non si nota una suddivisione in classi separabile dopo l'applicazione di PCA sia in 2D che in 3D

Provando a usare K-means su questi due risultati

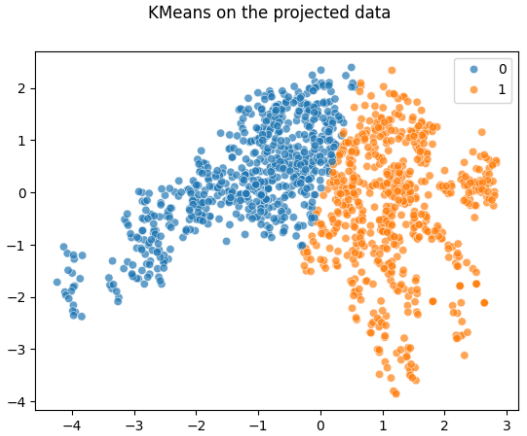

Figure 5: t-SNE

Figure 6: k-means on 3D PCA

Anche se sembrerebbe che k-means (con k=2) riesca a separare i cluster, non sono assolutamente significativi in quanto non rappresentano le classi di interesse, i cluster inoltre non sono veramente ben seprati fra loro. Cosa che accade con t-SNE come mostrato nel grafico sotto.

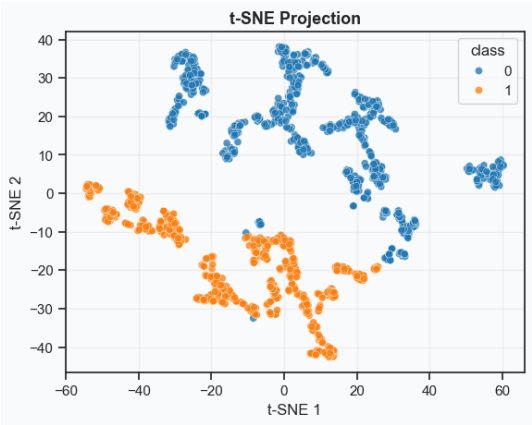

Figure 7: k-means on 2D PCA

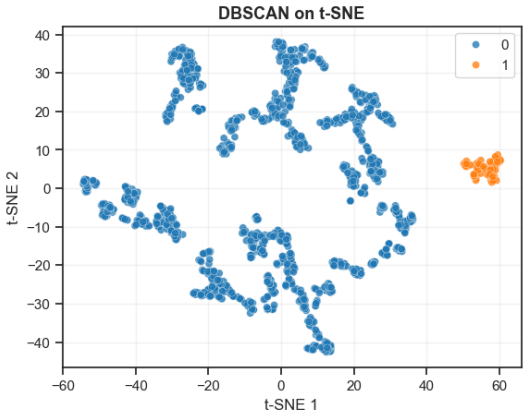

Figure 8: DBSCAN eps=9

T-SNE aiuta a separare signitificamente i cluster evidenziando la natura complessa e sopratutto non lineare del dataset. DBSCAN aiuta a trovare una separazione sui cluster ma non riproduce le classi del dataset originale anche se individua il rumore nei dati.

L'unsupervised learning quindi fallisce a trovare una separazione significativa delle classi e questo ci porta ad utilizzare tecniche di supervised learning

5 Supervised Learning

In questa sezione andiamo ad osservare i risultati per i modelli da testare sul dataset

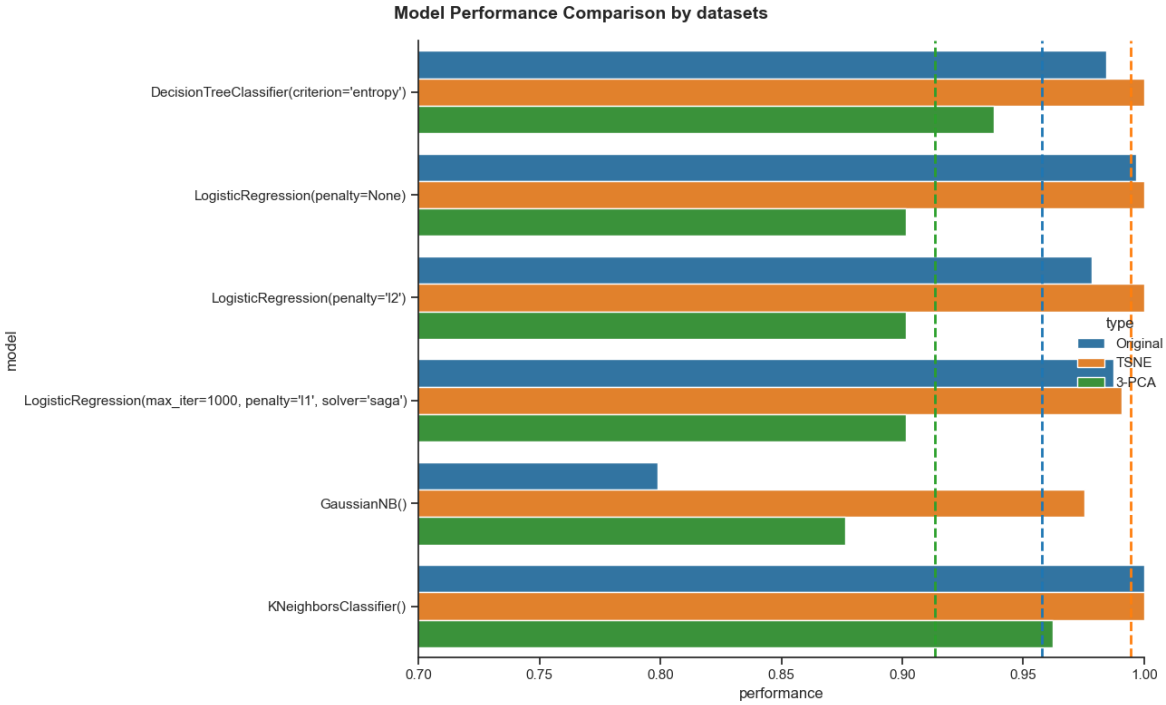

Figure 9: performance dei modelli

6 Conclusione

In base a quanto visto, e in base all'analisi fatta sul dataset di banconote, si evidenzia l'importanza della scelta e dell'uso degli giusti strumenti relativamente ai dati e a come sono disposti. In questo

caso, il dataset non può essere separato con metodi lineari, come si evince dall'analisi fatta con PCA e K-means. Applicando t-SNE però, è possibile verificare come si riesca a classificare bene i dati nelle due classi originali anche se, la seprazione non è stata significativa ai fini dei nostri obiettivi, quindi si è passati al supervised learning.

Durante il supervised learning poi si è potuto vedere come questa classificazione si è potuta eseguire tranquillamente senza usare PCA o t-SNE. Globalmente tutti i modelli sono riusciti a seprare correttamente il dataset ma KNN si è dimostrato il miglior modello (accuracy: 1) seguito dal modello con regressione logistica e infine Naive-Bayes, quest'ultimo casusato dalla mancaza di indipendenza fra le variabili e dalla distribuzione delle stesse, infatti Naive-Bayes presupponde una distribuzione normale.

7 Improvements

L'aggiunta in preprocessing di una trsformazione t-SNE potrebbe aiutare con lo score dei modelli anche se nel caso di KNN (F1 score = 1) non c'è possibilità di miglioria alcuna, si noti l'uso della cross-validation in questo caso, il modello non è andato in overfitting. Il dataset, presentando una complessità di fondo, non può essere ben approssimato linearmente (PCA), deve quindi essere processato tramite algoritmi non lineari (T-SNE, KNN).